

Mô tả thuật toán SGD

Đinh Thái Sơn

1. Cập nhật Gradient Ngẫu nhiên (Stochastic Gradient Updates)

Trong học sâu (deep learning), hàm mục tiêu (objective function) thường là trung bình của các hàm lỗi (loss function) cho mỗi ví dụ trong tập dữ liệu huấn luyện. Cho một tập dữ liệu huấn luyện gồm n ví dụ, chúng ta giả định rằng $f_i(\mathbf{x})$ là hàm lỗi đối với ví dụ huấn luyện có chỉ số i , trong đó $\mathbf{x}$ là vector tham số. Khi đó, hàm mục tiêu là

$$f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}).$$

(1.1)

Gradient của hàm mục tiêu tại $\mathbf{x}$ được tính là

$$\nabla f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}).$$

(1.2)

Nếu sử dụng gradient descent, chi phí tính toán cho mỗi lần lặp độc lập là $O(n)$, tăng tuyến tính theo n . Do đó, khi tập dữ liệu huấn luyện lớn hơn, chi phí của gradient descent cho mỗi lần lặp sẽ cao hơn.

****Stochastic gradient descent (SGD)**** (Gradient Descent Ngẫu nhiên) làm giảm chi phí tính toán ở mỗi lần lặp. Ở mỗi lần lặp của stochastic gradient descent, chúng ta lấy mẫu đồng đều một chỉ số $i \in \{1, \dots, n\}$ cho các điểm dữ liệu một cách ngẫu nhiên, và tính $\nabla f_i(\mathbf{x})$ để cập nhật $\mathbf{x}$:

$$\mathbf{x} \leftarrow \mathbf{x} - \eta \nabla f_i(\mathbf{x}),$$

(1.3) trong đó η là learning rate (tốc độ học). Chúng ta có thể thấy chi phí tính toán cho mỗi lần lặp giảm từ $O(n)$ của gradient descent xuống mức hằng số $O(1)$. Hơn nữa, chúng ta muốn nhấn mạnh rằng gradient ngẫu nhiên $\nabla f_i(\mathbf{x})$ là một ước lượng không thiên vị (unbiased estimate) của gradient đầy đủ $\nabla f(\mathbf{x})$ vì

$$\mathbb{E}[\nabla f_i(\mathbf{x})] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}) = \nabla f(\mathbf{x}).$$

(1.4)

Điều này có nghĩa là, trung bình, gradient ngẫu nhiên là một ước lượng tốt của gradient.

2. Thuật toán Stochastic Gradient Descent Adaptive Algorithm–SGDA

Bước 0. Chọn $x^0 \in C$, $\lambda_0 \in (0, +\infty)$, $\sigma, \kappa \in (0, 1)$. Đặt $k = 0$.

Bước 1. Lấy mẫu ξ^k và tính x^{k+1} và λ_{k+1} như sau:

$$x^{k+1} = P_C(x^k - \lambda_k \nabla f_{\xi^k}(x^k)),$$

Nếu $f_{\xi^k}(x^{k+1}) \leq f_{\xi^k}(x^k) - \sigma \langle \nabla f_{\xi^k}(x^k), x^k - x^{k+1} \rangle$ thì đặt $\lambda_{k+1} := \lambda_k$ ngược lại đặt $\lambda_{k+1} := \kappa \lambda_k$.

Bước 2. Cập nhật $k := k + 1$. Nếu $x^{k+1} = x^k$ thì **DỪNG** ngược lại chuyển đến **Bước 1**.

3 Chứng minh

Xét bài toán tối ưu lồi

$$\min_{x \in C} F(x) := \mathbb{E}[f_{\xi}(x)],$$

trong đó $C \subset \mathbb{R}^d$ là tập đóng và lồi. Giả sử:

i. Với mọi ξ , hàm f_ξ là L -smooth:

$$\|\nabla f_\xi(x) - \nabla f_\xi(y)\| \leq L\|x - y\|.$$

Suy ra F cũng là L -smooth.

ii. Gradient mẫu là công bằng và có phương sai hữu hạn (lấy $g_k = \nabla f_{\xi^k}(x^k)$):

$$F(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}) \implies \mathbb{E}_i[\nabla f_i(\mathbf{x})] = \nabla F(\mathbf{x}) \implies$$

$$\mathbb{E}[g_k | x^k] = \nabla F(x^k), \quad \mathbb{E}[\|g_k - \nabla F(x^k)\|^2] \leq \sigma^2.$$

iii. Thuật toán chọn bước λ_k bằng backtracking sao cho

$$0 < \lambda_k \leq \bar{\lambda} < \frac{2}{L}.$$

Thuật toán SGDA sinh ra dãy:

$$x^{k+1} = P_C(x^k - \lambda_k \nabla f_{\xi^k}(x^k)).$$

Bổ đề: Hạ ước lượng giảm trị hàm

Vì F là L -smooth, ta có

$$F(x^{k+1}) \leq F(x^k) + \langle \nabla F(x^k), x^{k+1} - x^k \rangle + \frac{L}{2} \|x^{k+1} - x^k\|^2.$$

Đặt $\Delta_k := x^{k+1} - x^k$. Thêm bớt gradient mẫu:

$$\langle \nabla F(x^k), \Delta_k \rangle = \langle \nabla f_{\xi^k}(x^k), \Delta_k \rangle + \langle \nabla F(x^k) - \nabla f_{\xi^k}(x^k), \Delta_k \rangle.$$

Từ tính chất của phép chiếu lên tập lồi ta có

$$\langle \nabla f_{\xi^k}(x^k), \Delta_k \rangle \leq -\frac{1}{\lambda_k} \|\Delta_k\|^2.$$

Do đó

$$F(x^{k+1}) \leq F(x^k) - \left(\frac{1}{\lambda_k} - \frac{L}{2} \right) \|\Delta_k\|^2 + \langle \nabla F(x^k) - \nabla f_{\xi^k}(x^k), \Delta_k \rangle.$$

Lấy kỳ vọng

Lấy kỳ vọng theo ξ^k và dùng (ii):

$$\mathbb{E}[\langle \nabla F(x^k) - \nabla f_{\xi^k}(x^k), \Delta_k \rangle] \leq \sigma \mathbb{E}\|\Delta_k\|.$$

Dùng bất đẳng thức Young ($\langle a, b \rangle \leq \frac{1}{2\alpha} \|a\|^2 + 2\alpha \|b\|^2$):

$$\sigma \|\Delta_k\| \leq \frac{\varepsilon}{2} \|\Delta_k\|^2 + \frac{\sigma^2}{2\varepsilon}.$$

Chọn $\varepsilon = \frac{1}{\lambda} - \frac{L}{2} > 0$. Khi đó

$$\mathbb{E}[F(x^{k+1})] \leq \mathbb{E}[F(x^k)] - \underbrace{\left(\frac{1}{\lambda_k} - \frac{L}{2} - \frac{\varepsilon}{2} \right)}_{\geq \delta > 0} \mathbb{E}\|\Delta_k\|^2 + \frac{\sigma^2}{2\varepsilon}.$$

Vì $\lambda_k \leq \bar{\lambda}$, ta có hằng số $\delta > 0$ cố định.

Suy ra

$$\mathbb{E}[F(x^{k+1})] \leq \mathbb{E}[F(x^k)] + c_0, \quad c_0 := \frac{\sigma^2}{2\varepsilon}.$$

Chứng minh hội tụ

Vì F lồi và bị chặn dưới bởi $F^\star$, nên dãy

$$\mathbb{E}[F(x^k)]$$

là giảm trừ một sai số hằng c_0 và bị chặn dưới.

Lấy tổng từ $k = 0$ đến $N - 1$:

$$\sum_{k=0}^{N-1} \delta \mathbb{E} \|\Delta_k\|^2 \leq \mathbb{E}[F(x^0)] - F^\star + N c_0.$$

Suy ra

$$\frac{1}{N} \sum_{k=0}^{N-1} \mathbb{E} \|\Delta_k\|^2 \rightarrow \frac{c_0}{\delta}.$$

Trong trường hợp không nhiễu ($\sigma = 0$) ta có $\Delta_k \rightarrow 0$, và do $x^{k+1} - x^k = -\lambda_k P_C(\nabla F(x^k))$,

$$\nabla F(x^k) \rightarrow 0.$$

Do F lồi, từ $\nabla F(x^k) \rightarrow 0$ suy ra x^k hội tụ đến nghiệm tối ưu và

$$\mathbb{E}[F(x^k)] \rightarrow F^\star.$$